

# 凸优化第三次上机作业

黄晃数院 1701210098

2018 年 11 月 26 日

## 1 问题

原问题为

$$\min \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1 \quad (1)$$

### 1.1 cvx calling mosek or gurobi

因为primal 1是个凸问题,cvx下可以直接

$$\text{minimize}(1/2\text{sum\_square}(A * x - b) + \mu * \text{norm}(x, 1))$$

## 2 算法

### 2.1 ALM求解对偶问题

#### 2.1.1 对偶问题

首先将原问题转化为对偶问题,做线性变换

$$\begin{aligned} \min \quad & \frac{1}{2} \|y\|_2^2 + \mu \|x\|_1 \\ \text{s.t.} \quad & y = Ax - b. \end{aligned} \quad (2)$$

对应的lagrangian函数为

$$L(x, y, \lambda) = \frac{1}{2} \|y\|_2^2 + \mu \|x\|_1 + \lambda^T (Ax - b - y)$$

直接可求得

$$g(\lambda) = -\frac{1}{2}\|\lambda\|_2^2 - \lambda^T b, \quad \|A^T \lambda\|_\infty \leq \mu$$

所以对偶问题(D)可写作

$$\begin{aligned} \min \quad & \frac{1}{2}\|\lambda\|_2^2 + \lambda^T b \\ \text{s.t.} \quad & \|A^T \lambda\|_\infty \leq \mu. \end{aligned} \quad (3)$$

### 2.1.2 对偶的增广lagrangian函数

引入变量 $s, A^T \lambda = s, \|s\|_\infty \leq \mu$ , 则对应的增广lagrangian函数为

$$L_t(\lambda, s, x) = \frac{1}{2}\|\lambda\|_2^2 + \lambda^T b + x^T (A^T \lambda - s) + \frac{t}{2}\|A^T \lambda - s\|_2^2, \quad s_k \leq \mu.$$

令 $C = \{s \mid \|s\|_\infty \leq \mu\}$ , 那么增广lagrangian函数也可以写作

$$L_t(\lambda, s, x) = \frac{1}{2}\|\lambda\|_2^2 + \lambda^T b + I_C(s) + x^T (A^T \lambda - s) + \frac{t}{2}\|A^T \lambda - s\|_2^2$$

由增广Lagrangian方法, 我们需要: 对于给定的 $x$ , 求 $s, \lambda$ 极小化 $L_t(\lambda, s, x)$ , 我们利用增广lagrangian函数的第一种表述来进行非精确的求解, 即在全空间求极小, 然后在 $C$ 上对 $s$ 做投影. 利用一阶条件, 这等价于

$$s_i = \begin{cases} \mu & \phi(\lambda, x)_i > \mu \\ -\mu & \phi(\lambda, x)_i < -\mu \\ \phi(\lambda, x) & \text{else} \end{cases}$$

$$\phi(\lambda, x) = A^T \lambda + \frac{x}{t}, \quad \lambda = (I + tAA^T)^{-1}(tAs - Ax - b)$$

显式的按上列顺序进行 $N$ 次迭代的结果作为 $s^+, \lambda^+$ , 然后更新 $x$

$$x^+ = x + t(A^T \lambda - s)$$

## 2.2 ADMM for DUAL

转化为对于初值 $x, \lambda$ , 求 $s$ 极小化增广lagrangian, 然后对 $x, s^+$ , 求 $\lambda$ 极小化增广lagrangian, 然后更新 $x$ .

转化为算法, 等价于上面ALM的 $N$ 次迭代直接取值为1即可.

### 2.3 ADMM for linearization primal problem

对于原问题,其增广lagrangian函数为

$$L(x, y, \lambda) = \frac{1}{2}\|y\|_2^2 + \mu\|x\|_1 + \frac{\beta}{2}\|Ax - b - y\|_2^2 + z^T Ax - z^T y - z^T b$$

ADMM迭代为

$$\begin{aligned} x &= \arg \min_x \mu\|x\|_1 + \frac{\beta}{2}\|Ax - b - y\|_2^2 + z^T Ax \\ y &= \arg \min_y \frac{1}{2}\|y\|_2^2 + \frac{\beta}{2}\|Ax - b - y\|_2^2 + -z^T y \\ z &= z + \beta(Ax - y - b). \end{aligned}$$

在求解关于x的极小化问题时,因为有一范数项,选择通过线性化的方式求解,即取

$$g = \beta A^T(Ax - y - b) + z^T A$$

解

$$\begin{aligned} x &= \arg \min_x \mu\|x\|_1 + x^T g + \frac{1}{2t}\|x - x_k\|_2^2 \\ &= \arg \min_y t\mu\|x\|_1 + x^T g + \frac{1}{2}\|x - (x_k - tg)\|_2^2 \\ &= \text{Prox}_{t\mu\|\cdot\|_1}(x_k - tg) \end{aligned}$$

其中 $\frac{1}{t} = \beta\lambda_{\max}(A^T A)$ 为二阶导的近似值.

关于y,z的更新,仍然为

$$\begin{aligned} y &= \frac{\beta(Ax - y - b) + z}{\beta + 1} \\ z &= z + \beta(Ax - y - b). \end{aligned}$$

实验证明该方法需要加上同伦才能较好收敛

## 3 数值结果

method	cpu	err
cvx-call-mosek:	1.12	0.00e+00
ALM for dual problem:	0.08	3.72e-06
ADMM for dual problem:	0.07	3.62e-06
linearization for primal:	0.79	2.41e-06

### 3.1 结果分析

- 三个算法都达到了要求精度
- ALM与ADMM方法有极好的收敛速度,符合预期
- ALM相较于ADMM方法虽然每次多了10步子迭代,然而对于合适的参数而言,效果并不比后者差
- 对原问题线性化之后收敛速度不如前两种方法,由于线性化损失了精度,需要同伦方法弥补,所以耗时更多是可以预料的