

凸优化 · 课程项目二

姓名：陈嘉豪

学号：1300010741

2017 年 1 月 9 日

1 LP 问题

LP 问题的标准形式如下

$$\begin{aligned} \min_{x \in R^n} \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned} \quad (1)$$

等价于对偶形式如下

$$\begin{aligned} \min_{y \in R^m, s \in R^n} \quad & -b^T y \\ \text{s.t.} \quad & A^T y + s = c \\ & s \geq 0 \end{aligned} \quad (2)$$

2 第一题

2.1 问题描述

- (a) 用 Augmented Lagrangian Method 解问题 (2), 使得变量 s 不出现在算法的更新过程中。
- (b) 用梯度法极小化子问题中的 Lagrangian 函数
- (c) 用 Semi-Smooth Newton Method 极小化子问题中的 Lagrangian 函数 [2]

2.2 (a) Augmented Lagrangian Method

对偶问题 (2) 等价于如下形式 (用 $-y$ 代替 y , 消去变量 s):

$$\begin{aligned} \min_{y \in R^m, s \in R^n} \quad & b^T y \\ \text{s.t.} \quad & A^T y + c \geq 0 \end{aligned}$$

参考 2, 有 Augmented Lagrangian Function 如下:

$$L_\sigma(y, x) = b^T y + \frac{1}{2\sigma} \left(\left\| \prod (x - \sigma(A^T y + c)) \right\|^2 - \|x\|^2 \right) \quad (3)$$

其中 \prod 为投影算子, 满足 $(\prod(x))_i = \begin{cases} x_i, & x_i > 0 \\ 0, & \text{else} \end{cases}$ 。Augmented Lagrangian Method

按照如下步骤进行迭代得到序列 $x^{(k)}$ 和 $y^{(k)}$ (参照 [2](3)):

$$\begin{aligned} y^{(k)} &= \arg \min_y L_{\sigma^{(k-1)}}(y, x^{(k-1)}) \\ x^{(k)} &= \prod (x^{(k-1)} - \sigma^{(k-1)}(A^T y + c)) \\ \sigma^{(k)} &= \rho \sigma^{(k-1)} \text{ or } \sigma^{(k)} = \sigma^{(k-1)} \end{aligned} \quad (4)$$

2.3 (b) 用梯度下降法求解子问题

为了解决迭代过程中 $y^{(k)}$ 的更新问题, 考虑采用梯度下降法。其中 $\phi(y) = L_\sigma(y, x)$ 对 y 的梯度为

$$\nabla\phi(y) = b - A \prod (x - \sigma(A^T y + c)) \quad (5)$$

用梯度下降法得到序列 $z^{(1)} = y^{(k-1)}, z^{(j+1)} = z^{(j)} - \text{step} * \nabla\phi(z^{(j)})$, 直到小于给定常数 ϵ 。

2.4 (c) 用 Semi-Smooth Newton Method 求解子问题

为了解决迭代过程中 $y^{(k)}$ 的更新问题, 考虑采用 Semi-Smooth Newton Conjugate Gradient Method [2]。

2.5 数值实验结果

3 第二题

3.1 问题描述

Semi-Smoothed Method 基于求解一个不动点方程

(a) 用 Douglas-Rachford Splitting (DRS) 解问题 (1), 用 ADMM 解 (2)

(b) 推导上述 DRS 和 ADMM 中的变量的显式关系

(c) 用正则化的 Semi-Smooth Newton Method 求解问题 (2) [1]

3.2 DRS 与 ADMM

给定如下问题

$$\min f(x) = g(x) + h(x)$$

Douglas-Rachford Splitting (DRS) 算法按照如下格式进行迭代

$$\begin{cases} y^+ = \text{prox}_{tg}(x - w) \\ x^+ = \text{prox}_{th}(y^+ + w) \\ w^+ = w + y^+ - x^+ \end{cases} \quad (6)$$

其中 $\text{prox}_h(x) = \arg \min_u \left(h(u) + \frac{1}{2} \|u - x\|_2^2 \right)$ 。

给定如下问题

$$\begin{aligned} \min_{y,z} \quad & f(y) + g(z) \\ \text{s.t} \quad & Ay + Bz = b \end{aligned}$$

和 Augmented Lagrangian Function 如下 (x 为乘子):

$$L(y, z, x) = f(y) + g(z) + \beta x^T (Ay + Bz - b) + \frac{\beta}{2} \|Ay + Bz - b\|_2^2 \quad (7)$$

Alternating Direction Method of Multipliers (ADMM) 算法按照如下格式进行迭代

$$\begin{cases} y^+ &= \arg \min_y L(y, z, x) \\ &= \arg \min_y (f(y) + \beta x^T Ay + \frac{\beta}{2} \|Ay + Bz - b\|_2^2) \\ z^+ &= \arg \min_z L(y^+, z, x) \\ &= \arg \min_z (g(z) + \beta x^T Bz + \frac{\beta}{2} \|Ay^+ + Bz - b\|_2^2) \\ x^+ &= x + (Ay^+ + Bz^+ - b) \end{cases} \quad (8)$$

当原问题可分,

$$\begin{aligned} \min \quad & f_1(x_1) + f_2(x_2) \\ \text{s.t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned}$$

转化为对偶问题即

$$\max \quad -b^T z - f_1^*(-A_1^T z) - f_2^*(-A_2^T z)$$

令 $g(z) \triangleq b^T z + f_1^*(-A_1^T z)$, $h(z) \triangleq f_2^*(-A_2^T z)$, 对该对偶问题使用 DRS (6), 等价于如下形式,

$$\begin{aligned} //y^+ &= \text{prox}_{tg}(z - w) \\ \hat{x}_1^+ &= \arg \min_{x_1} \left(f_1(x_1) + z^T (A_1 x_1 - b) + \frac{t}{2} \|A_1 x_1 + A_2 \hat{x}_2 - b\|_2^2 \right) \\ y^+ &= z - w + t(A_1 \hat{x}_1^+ - b) \\ //z^+ &= \text{prox}_{th}(y^+ + w) = \text{prox}_{th}(z + t(A_1 \hat{x}_1^+ - b)) \\ \hat{x}_2^+ &= \arg \min_{x_2} \left(f_2(x_2) + z^T A_2 x_2 + \frac{t}{2} \|A_1 \hat{x}_1^+ + A_2 x_2 - b\|_2^2 \right) \\ z^+ &= z + t(A_1 \hat{x}_1^+ + A_2 \hat{x}_2^+ - b) \\ //w^+ &= w + y^+ - z^+ \\ w^+ &= -tA_2 \hat{x}_2^+ \end{aligned} \quad (9)$$

将上述迭代与 (8) 比较可知, 将 DRS 用于对偶问题等价于将 ADMM 用于原问题。而且 $\beta = t$, 上式中的 \hat{x}_1, \hat{x}_2 分别等于 ADMM 中的两个变量 y, z ; 目标变量也是一致的, 上式中 z 的更新形式与 (8) 中 x 的更新形式完全一致。

3.3 用 ADMM 解对偶问题

首先给出 ADMM 用于解对偶问题的方式, 将对偶问题 (2) 转化为如下形式

$$\begin{aligned} \min_{y,s} \quad & -b^T y + I_{s \geq 0} \\ \text{s.t.} \quad & A^T y + s = c \end{aligned} \quad (10)$$

将 ADMM 算法 (8) 应用到该问题中, 得到如下迭代。

$$\begin{cases} y^+ &= (AA^T)^{-1}(\frac{1}{\beta}b + A(c - s - x)) \\ s^+ &= \Pi(c - A^T y^+ - x) \\ x^+ &= x + (A^T y^+ + s^+ - c) \\ &= s^+ - (c - A^T y^+ - x) \geq 0 \end{cases} \quad (11)$$

3.4 用 DRS 解原问题

为了给出 DRS 和 ADMM 变量之间的显式关系, 参考3.2中的迭代形式9, 有如下的对照表

$f_1(x)$	$f_2(x)$	x_1	x_2	A_1	A_2	b	β
$-b^T x_1$	$I_{x \geq 0}$	$y_{(\text{ADMM})}$	$s_{(\text{ADMM})}$	A^T	I	c	t

表 1: 对照表

依照该表得到对应的 g, h 如下

$$\begin{aligned} g(x) &= b^T x + f_1^*(-A_1^T x) \\ &= c^T x + I_{Ax=b} \\ h(x) &= f_2^*(-A_2^T x) \\ &= I_{x \geq 0} \end{aligned} \quad (12)$$

其中 $f_1^*(y) = \sup_x (y^T x + b^T x) = I_{y=-b}$, $f_2^*(y) = \sup_x (y^T x - I_{x \geq 0}) = I_{y \leq 0}$ 。于是有原问题的等价形式如下

$$\min g(x) + h(x) = c^T x + I_{Ax=b} + I_{x \geq 0}$$

对该形式下的原问题使用 DRS 等价于将 ADMM 用于对偶问题, 参照迭代格式 (9) 与表 (1) 可知, DRS 的迭代格式、变量与 (11) 中变量的关系如下

$$\begin{cases} // \hat{x}_1 &= y_{(\text{ADMM})} \\ // \hat{x}_2 &= s_{(\text{ADMM})} \\ y^+ &= x - w + t(A^T \hat{x}_1^+ - c) \\ x^+ &= x + t(A^T \hat{x}_1^+ + \hat{x}_2^+ - c) \\ w^+ &= -\beta \hat{x}_2^+ \end{cases} \quad (13)$$

当 $\beta = t = 1$ 时, 可以看到 (11) 和 (13) 中的目标变量的更新完全一致。

3.5 数值实验结果

4 数值实验结果对比

参考文献

- [1] Xiantao Xiao, Yongfeng Li, Zaiwen Wen, and Liwei Zhang. A regularized semi-smooth newton method with projection steps for composite convex programs, 2016.
- [2] Xin Yuan Zhao, Defeng Sun, and Kim Chuan Toh. A newton-cg augmented lagrangian method for semidefinite programming. *Siam Journal on Optimization*, 20(4):1737–1765, 2010.