

# 统计学习第一次上机作业

黄晃数院 1701210098

2018 年 12 月 3 日

## 1 结果

### 1.1 问题一

$n=100, p=5000$ .

$$\beta_i = (-1)^i \exp(-2 * (i - 1)/20), x_i \sim N(0, 1)$$

$$y = X\beta + kz$$

.其中  $z \sim N(0, 1)$ , 取  $k$  使得  $\text{SNR}=3$ . 基于 matlab 实现了对偶问题的 ADMM 方法, 作为对照, 使用 matlab 中的 cvx 包进行了对应问题的求解.

$\lambda$  的选取  $\lambda - \min = 1e - 3, \lambda - \max = 1, \lambda_i = \lambda - \min * 10^{(i-1)*3/100}$

#### 1.1.1 solution-path





图 1: solution path

图 2: solution path (15个最大的 $\beta$ )

### 1.1.2 与cvx的相对误差及cpu时间

算法以最大步长以及变量的下降量作为终止准则.  $F$ 为目标函数, 定义相对误差为:

$$err = \frac{(F(x_0) - F(x_1))}{F(x_1)}$$

其中 $x_1$ 是通过cvx得到的解.




图 3: error and time

### 1.1.3 小结

- 根据图一, 可以看到实现的admm有稀疏性, 并且结果和cvx的相似.
- 由图三, admm正确的求解了问题, 并且在 $\lambda$ 较小时求解精确(相对误差 $1e-4$ ). 但在 $\lambda$ 较大时误差开始变大
- admm的时间花费在cvx的4-6倍左右.

分析以及可能改进的地方 上面提到的误差变大的问题,可能产生于admm方法的参数选取(现在是选择的统一的t,没有随着 $\lambda$ 变化).算法内部的参数t根据 $\lambda$ 变化可能会有改进.

## 1.2 问题二

# 2 算法

## 2.1 Lasso For Linear Regression

原问题为

$$\min \frac{1}{2} \|Ax - b + x_0 * \vec{1}\|_2^2 + \mu \|x\|_1 \quad (1)$$

其中 $x = [x_1, x_2, \dots, x_p]^T$

### 2.1.1 ALM求解对偶问题

对偶问题 首先将原问题转化为对偶问题,做线性变换

$$\begin{aligned} \min \quad & \frac{1}{2} \|y\|_2^2 + \mu \|x\|_1 \\ \text{s.t.} \quad & y = Ax - b + x_0 * \vec{1}. \end{aligned} \quad (2)$$

对应的lagrangian函数为

$$L(x, y, \lambda) = \frac{1}{2} \|y\|_2^2 + \mu \|x\|_1 - \lambda^T (Ax - b - y + x_0 * \vec{1})$$

直接可求得

$$\begin{aligned} g(\lambda) &= -\frac{1}{2} \|\lambda\|_2^2 + \lambda^T b \\ \|A^T \lambda\|_\infty &\leq \mu, \quad \lambda^T * \vec{1} = 0 \end{aligned}$$

所以对偶问题(D)可写作

$$\begin{aligned} \min \quad & \frac{1}{2} \|\lambda\|_2^2 - \lambda^T b \\ \text{s.t.} \quad & \|A^T \lambda\|_\infty \leq \mu. \\ & \lambda^T * \vec{1} = 0 \end{aligned} \quad (3)$$

**对偶的增广lagrangian函数** 引入变量 $s, A^T \lambda = s, \|s\|_\infty \leq \mu$ , 则对应的增广lagrangian函数为

$$L_t(\lambda, s, x) = \frac{1}{2} \|\lambda\|_2^2 - \lambda^T b + x^T (A^T \lambda - s) + \frac{t}{2} \|A^T \lambda - s\|_2^2, \quad s_k \leq \mu, \quad \lambda^T * \vec{1} = 0$$

由增广Lagrangian方法, 我们需要: 对于给定的 $x$ , 求 $s, \lambda$ 极小化 $L_t(\lambda, s, x)$ .

**s的求解** 在此对 $c$ 进行非精确的求解, 即在全空间求极小, 然后在 $C$ 上对 $s$ 做投影. 利用一阶条件, 这等价于

$$s_i = \begin{cases} \mu, & \text{if } \phi(\lambda, x)_i > \mu \\ -\mu, & \text{if } \phi(\lambda, x)_i < -\mu \\ \phi(\lambda, x), & \text{else} \end{cases}$$

$$\phi(\lambda, x) = A^T \lambda + \frac{x}{t}$$

**$\lambda$ 的求解**  $\lambda$ 为问题

$$\begin{aligned} \min & \frac{1}{2} \|\lambda\|_2^2 - \lambda^T b + x^T A^T \lambda + \frac{1}{2} t \lambda^T A^T A \lambda - t \lambda^T A s \\ \text{sub} & \lambda^T * \vec{1} = 0 \end{aligned} \quad (4)$$

考虑其对偶问题, 引入对偶变量 $\psi$  Lagrangian方程为

$$L = \frac{1}{2} \|\lambda\|_2^2 - \lambda^T b + x^T A^T \lambda + \frac{1}{2} t \lambda^T A^T A \lambda - t \lambda^T A s + \psi(\lambda^T * \vec{1})$$

$$g(\psi) = \min_{\lambda} L(\lambda, \psi)$$

而

$$\frac{\partial L}{\partial \lambda} = (tA^T A + I)\lambda - (tAs - Ax + b - \psi * \vec{1})$$

取 $\lambda = (tA^T A + I)^{-1}(tAs - Ax + b - \psi * \vec{1})$ 得

$$g(\psi) = -\frac{1}{2} (tAs - Ax + b - \psi * \vec{1})^T (tA^T A + I)^{-1} (tAs - Ax + b - \psi * \vec{1})$$

由一阶条件可知

$$\psi = \frac{\vec{1}^T (tA^T A + I)^{-1} (tAs - Ax + b)}{\vec{1}^T (tA^T A + I)^{-1} \vec{1}}$$

显式的按上列顺序计算 $s^+, \lambda^+$ , 然后更新 $x$

$$x^+ = x + t(A^T \lambda - s)$$

综上,算法可以描述为

$$\begin{aligned}
 s &= \min(\max(\phi(\lambda, x), -\mu), \mu) \\
 \psi &= \frac{\vec{1}^T (tA^T A + I)^{-1} (tAs - Ax + b)}{\vec{1}^T (tA^T A + I)^{-1} \vec{1}} \\
 \lambda &= (tA^T A + I)^{-1} (tAs - Ax + b - \psi * \vec{1}) \\
 x &= x + t(A^T \lambda - s).
 \end{aligned}$$

对应到原问题的变量,

$$\begin{aligned}
 y &= -\lambda \\
 x0 &= \text{mean}(y - Ax + b)
 \end{aligned}$$